

1-KalmanFilterIntroduction

navigation-algorithm

1-KalmanFilterIntroduction

Reference

- 1 Kalman Filter的来源
- 2 KF理解
- 3 kalman在一维情况下的例子
- 4 扩展至高维度
- 5 使用非线性函数来扩展KF成为EKF
- 6 调参经验之谈
- 7 KF内矩阵的认识理解

Reference

- [how-a-kalman-filter-works-in-pictures](#)
- [kalman filter 基本思想](#)
- [robot_localization ros pkg](#)
- [Kalman Filter 通俗讲解](#)
- [ekf tutorial](#)
- [手把手教你写卡尔曼滤波器](#)
- HOPE TO READING Book:

Poor Man's Explanation of Kalman Filtering: Or How I Stopped Worrying & Learned to Love Matrix Inversion

1 Kalman Filter的来源

使用bayes filter来实现广泛使用的一项技术就是kalman filter(KF) , KF在1958年被Swerling

和Kalman在研究linear gaussian system的滤波和预测时发明的。KF实现了对连续状态空间的belief computation。它不能用于离散或者混合状态空间。

2 KF理解

- K_k 卡尔曼增益实际上是表示观测量 z_k 的权重,如果相信 z_k 更多一些,那么这个增益就越大.
- 关于自己的理解

用 $k-1$ 时刻的状态量来预测,得到 k 时刻的先验状态量估计值和先验估计偏差,然后计算测量值的可靠程度(卡尔曼增益),最后结合 k 时刻的测量值,得到 k 时刻的后验最优估计值和其偏差

- 使用KF问题场景：
 - 一个sensor获取机器人state
 - 一个sensor可以predict机器人state，抽象出一个预测方程，预测state和该state对应的covariance
- KF假设：
变量是随机的并且是高斯分布的，对应均值 μ 和方差 σ^2 ,方差用来表示数据的不确定性

3 kalman在一维情况下的例子

- Model
$$x_k = ax_{k-1} + bu_k + \omega_k$$
 状态转移方程
$$z_k = cx_k + v_k$$
 观测方程
- predict
$$\hat{x}_k = a\hat{x}_{k-1} + bu_k$$
$$p_k = ap_{k-1}a + q$$
- update
$$g_k = p_k c / (cp_k c + r)$$
$$\hat{x}_k \leftarrow \hat{x}_k + g_k(z_k - c\hat{x}_k)$$
$$p_k \leftarrow (1 - g_k c)p_k$$

$\omega_k \sim N(0, q)$ 表示模型控制的噪声方差

$v_k \sim N(0, r)$ 表示观测量(传感器)的噪声方差

g_k 表示卡尔曼增益

p_k 表示预测的方差

4 扩展至高维度

- Model

$x_k = Ax_{k-1} + Bu_k + \omega_k$ 状态转移型方程

$z_k = Hx_k + v_k$ 观测方程

- predict

$\hat{x}_k = A\hat{x}_{k-1} + Bu_k$

$P_k = AP_{k-1}A^T + Q$

- update

$G_k = P_k H^T (HP_k H^T + R)^{-1}$

$\hat{x}_k \leftarrow \hat{x}_k + G_k(z_k - H\hat{x}_k)$

$P_k \leftarrow (1 - G_k H)P_k$

$\omega_k \sim N(0, Q)$ 表示模型控制的噪声方差

$v_k \sim N(0, R)$ 表示观测量(传感器)的噪声方差

G_k 表示卡尔曼增益

P_k 表示预测的方差

H 相当于一维里面的 c

5 使用非线性函数来扩展KF成为EKF

- Model

$x_k = f(x_{k-1}, u_k) + w_k$

$z_k = h(x_k) + v_k$

- predict

$\hat{x}_k = f(\hat{x}_{k-1}, u_k)$

$$P_k = F_{k-1} P_{k-1} F_{k-1}^T + Q_{k-1}$$

- update

$$G_k = P_k H_k^T (H_k P_k H_k^T + R)^{-1}$$

$$\hat{x}_k \leftarrow \hat{x}_k + G_k (z_k - h(\hat{x}_k))$$

$$P_k \leftarrow (I - G_k H_k) P_k$$

其中, F_k 是 $f(x_{k-1}, u_k)$ 的Jacobian矩阵, H_k 是 $h(x_k)$ 的Jacobian矩阵

6 调参经验之谈

- P初始化不能给0, 一般设置为1
- R是根据传感器的数据方差设置的, 两个传感器的协方差一般设置为0
- Q对整个系统存在影响, 但又不能太确定对系统的影响有多大。工程上, 我们一般将Q设置为单位矩阵参与运算

7 KF内矩阵的认识理解

- A 或者 F 状态转移矩阵 (state transistion matrix) 有模型的状态转移方程决定
- B
- P 状态协方差矩阵 (state covariance matrix) 不可以初始化为0
- Q 过程噪声 (process covariance matrix) 工程上一般设置为I
- H 测量矩阵 (Measurement Matrix) 由模型的观测方程模型决定
- R 测量噪声矩阵 (measurement covariance matrix) , 由传感器的噪声决定
- K 卡尔曼增益 (Kalman Gain) , 用人话讲就是求y值的权值